



DeepNetGuard: NSL-KDD ile Derin Öğrenme Tabanlı Saldırı Tespit Sistemi (IDS)

Grup: DevTeam58

Üyeler:

Bayramcan Özgül	23040101010	bayramcanozgul@stu.topkapi.edu.tr
Ali Şahin	23040301065	alisahin1@stu.topkapi.edu.tr
Mehmet Emir Avcı	22040301048	mehmetemiravci@stu.topkapi.edu.tr
Yavuz Selim Bülbül	23040101046	yavuzselimbulbul@stu.topkapi.edu.tr
Tuğra Ortahisar	22040301042	tugraortahisar@stu.topkapi.edu.tr
Emirhan Bölükbaş	23040301102	emirhanbolukbas@stu.topkapi.edu.tr

GitHub: <https://github.com/tugra-ortr/DEV58>

Video: <https://youtu.be/Vna3GHZ-Wlk?si=oJZnbFXPmaWe0WxL>

Problem & Motivasyon

Günümüzde Siber Güvenlik Zorlukları

Dijital altyapıların hızla büyümesiyle birlikte siber saldırıların hem sayısı hem de karmaşıklığı artmaktadır. Geleneksel kural tabanlı güvenlik sistemleri, önceden tanımlı imzalara dayandığı için yeni ve gelişmiş saldırıları tespit etmekte yetersiz kalmaktadır.

- **Kural tabanlı sistemlerin sınırları:** Yeni saldırı türlerine adapte olamama
- **Yüksek yanlış pozitif oranları:** Operasyonel yük ve alarm yorgunluğu
- **Zero-day saldırılar:** Daha önce görülmemiş tehditlere karşı savunmasızlık

Projemizin Hedefi

Bu çalışmanın amacı, NSL-KDD veri seti üzerindeki ağ trafiği kayıtlarını analiz ederek, normal trafik ile saldırı trafiğini yüksek doğrulukla ayırt edebilen, derin öğrenme tabanlı bir Saldırı Tespit Sistemi (IDS) geliştirmektir. Çalışmada farklı derin öğrenme mimarileri karşılaştırılarak en uygun yaklaşım deneysel olarak değerlendirilmiştir.



Veri Seti: NSL-KDD

Eğitim Verisi

KDDTrain+

125,973 kayıt

Normal ve saldırı trafiği örneklerini içeren eğitim veri seti

Test Verisi

KDDTest+

22,544 kayıt

Modelin genelleme yeteneğini değerlendirmek için ayrılmış bağımsız test seti

Özellik Yapısı

41 özellik + 1 hedef


3 kategorik (protocol_type, service, flag) + 38 sayısal özellik

Veri Seti Özellikleri

NSL-KDD, ağ tabanlı saldırı tespit sistemlerinin değerlendirilmesi için yaygın olarak kullanılan bir benchmark veri setidir. Orijinal KDD Cup 99 veri setinin iyileştirilmiş bir versiyonudur ve tekrarlayan kayıtlar içermemektedir.

- **Protokol bilgileri:** TCP, UDP, ICMP
- **Servis tipleri:** HTTP, FTP, SMTP vb.
- **Bağlantı özellikleri:** Süre, paket sayısı, byte miktarı
- **İçerik özellikleri:** Root erişimi, dosya oluşturma, kabuk erişimi

NSL-KDD Test (KDDTest+) Sınıf Dağılımı



📄 **Etik Uygunluk:** NSL-KDD sentetik ve simüle edilmiş ağ trafiği içerir. Kişisel kimlik bilgisi (PII) veya gerçek kullanıcı verisi içermediği için etik açıdan güvenli ve akademik araştırmalar için uygundur.


Veri Dağılımı & Zorluklar

Sınıf Dağılımı Analizi

Veri setimiz ikili sınıflandırma problemi olarak ele alınmıştır: Normal trafik ve Attack (saldırı) trafiği. Hem eğitim hem de test veri setlerinde belirgin bir sınıf dengesizliği bulunmaktadır.

Dengesizlik Stratejilerimiz

- **Class Weights:** Azınlık sınıfına kayıp fonksiyonunda daha fazla ağırlık verme
- **Macro-F1 metriği:** Her sınıfın eşit önemde değerlendirilmesi
- **Sınıf bazlı değerlendirme:** Precision, Recall ve F1 skorlarının ayrı analizi



❏ **Kritik Nokta:** Sınıf dengesizliği nedeniyle yalnızca accuracy metriği yeterli değildir; bu nedenle macro-F1, precision ve recall metrikleri birlikte değerlendirilmiştir.

Ön İşleme Boru Hattı (Pipeline)

1

1. Kategorik Kodlama

Protocol_type, service ve flag gibi kategorik özellikler sayısal değerlere dönüştürüldü. Boyut artışını önlemek amacıyla LabelEncoder tercih edildi.

2

2. Özellik Ölçekleme

Tüm sayısal özellikler **StandardScaler** kullanılarak normalize edildi ($\mu=0$, $\sigma=1$). Bu adım, modelin daha hızlı ve kararlı şekilde öğrenmesini sağlar.

3

3. Train/Test Ayrımı

NSL-KDD veri setinin hazır train/test ayrımı kullanıldı. Bu yaklaşım, literatürdeki çalışmalarla adil ve tutarlı karşılaştırma yapılmasını sağlar.


4

4. Dengesizlik Yönetimi

Sınıf dengesizliği, kayıp fonksiyonuna entegre edilen class weights yöntemi ile yönetildi. Bu sayede azınlık sınıfının model öğreniminde daha etkili olması sağlandı.

Bu sistematik ön işleme süreci sayesinde, tüm modeller aynı ve tutarlı veri üzerinde eğitilmiş, sonuçların karşılaştırılabilirliği sağlanmıştır.

Yaklaşımımızın Özeti: Neden Çoklu Mimari?



Karşılaştırmalı Değerlendirme Yaklaşımı

Tek bir model yerine, **beş farklı derin öğrenme mimarisini** aynı veri ve ön işleme pipeline'ı ile karşılaştırmalı olarak değerlendirdik. Bu yaklaşım, hangi mimarinin NSL-KDD veri seti için daha uygun olduğunu deneysel olarak belirlememizi sağlamıştır.

- **Adil kıyaslama:** Tüm modeller aynı veri ve ön işleme pipeline'ı ile eğitildi
- **Mimari çeşitliliği:** Dense, CNN, ResNet, LSTM ve Attention tabanlı yapılar test edildi
- **Metrik zenginliği:** Accuracy, F1, precision ve recall birlikte değerlendirildi

01

Aynı Veri Pipeline

Tüm modeller aynı ön işleme adımlarından geçirilmiştir.

02

Beş Farklı Mimari

SimpleDNN, CNN, ResNetIDS, LSTM ve AttentionIDS mimarileri test edilmiştir.

03

Kapsamlı Metrikler

Modeller accuracy, weighted/macro F1, precision, recall ve confusion matrix ile değerlendirilmiştir.

04

En İyi Model Seçimi

Problem gereksinimlerine en uygun mimari, metrik karşılaştırmaları ile belirlenmiştir.

❏ **Değer Önerisi:** Bu yaklaşım, tek bir modelin önyargısına bağlı kalmadan, siber güvenlik verisi için hangi mimari yaklaşımın gerçekten daha etkili olduğunu bilimsel olarak ortaya koymamızı sağlamıştır.

Model Mimarileri (1/2)

	SimpleDNN (Baseline) Amaç: Diğer modellerle karşılaştırma yapabilmek için temel bir referans oluşturmak. Çok katmanlı tam bağlı (Dense) katmanlardan oluşan basit bir derin öğrenme modelidir. Düşük karmaşıklığı sayesinde hızlı eğitilir ve temel performans seviyesi sağlar. 3 Dense katman (128, 64, 32 nöron) - ReLU aktivasyon fonksiyonu - Dropout ile overfitting kontrolü - Parametre sayısı: ~12K Güçlü yön: Hızlı eğitim ve düşük hesaplama maliyeti
	CNN (Yerel Örüntü Tespiti) Amaç: Özellikler arasındaki yerel ilişkileri ve örüntüleri yakalamak. 1D evrişim katmanları kullanarak ardışık özellikler arasındaki pattern'ları öğrenir. Tabular ağ trafiği verisinde yerel özellik kombinasyonlarını etkili şekilde modelleyebilir. 3 Conv1D katman (64, 128, 64 filtre) - MaxPooling ve BatchNorm - Global Average Pooling - Parametre sayısı: ~85K Güçlü yön: Yerel özellik örüntülerini etkili şekilde öğrenme
	ResNetIDS (Derin Residual Öğrenme) Amaç: Daha derin ağlarda öğrenme kararlılığını artırmak. Residual (artık) bağlantılar sayesinde bilgi kaybı olmadan daha derin modellerin eğitilmesini sağlar. Bu yapı, öğrenmenin daha stabil olmasına ve performansın artmasına katkı sağlar. 4 Residual blok (her biri 2 Conv1D içerir) - Skip connection ile girdi-çıktı toplama - BatchNorm ve ReLU aktivasyon - Parametre sayısı: ~120K Güçlü yön: Derin yapılarda kararlı ve etkili öğrenme

Model Mimarileri (2/2)



LSTM (Long Short-Term Memory)

Amaç: Ağ trafiğindeki zamansal ve sıralı bağımlılıkları yakalamak.

LSTM mimarisi, ardışık bağlantılar arasındaki zaman ilişkilerini öğrenir. Bu sayede paket sırasına bağlı gelişen saldırı örüntülerini modelleyebilir.

- 2 LSTM katman (64 ve 32 gizli birim)
- Bidirectional LSTM (opsiyonel)
- Dropout (0.3) düzenlemesi
- Parametre sayısı: ~45K

Güçlü Yön: Sıralı ve zamansal saldırı davranışlarını tespit edebilme



AttentionIDS (Özellik Ağırlıklandırma)


Amaç: Her örnek için en önemli özelliklere dinamik olarak odaklanmak.

Attention mekanizması, modelin hangi özelliklerin daha kritik olduğunu öğrenmesini sağlar. Böylece saldırı tespitinde ayırt edici sinyallere daha fazla ağırlık verilir.

- Multi-head attention katmanı (4 head)
- Feed-forward network
- Layer normalization
- Parametre sayısı: ~95K

Güçlü Yön: Kritik özelliklere dinamik odaklanma

Model Karşılaştırması (Normal Recall)



Mimari Seçim Gerekçeleri

Her mimari, ağ trafiği verisindeki farklı bir sinyali veya örüntüyü yakalamaya odaklanır:

- **SimpleDNN:** Temel referans ve hızlı prototipleme
- **CNN:** Özellikler arası yerel örüntülerin yakalanması
- **ResNetIDS:** Derin ve karmaşık özellik etkileşimleri
- **LSTM:** Zamansal ve sıralı trafik davranışları
- **AttentionIDS:** Kritik özelliklere adaptif ve dinamik odaklanma

Bu çeşitlilik, hangi mimari yaklaşımın tabular IDS verisi için optimal olduğunu deneysel olarak göstermemizi sağlar.

Eğitim Stratejisi

Eğitim Hiperparametreleri

Kayıp Fonksiyonu

CrossEntropyLoss + Class Weights

CrossEntropyLoss, sınıf dengesizliğini dengelemek amacıyla **class weights** ile birlikte kullanıldı.

Optimizer & Learning Rate

Adam Optimizer

LR = 0.001 (başlangıç)

Weight Decay = 1e-4 (L2 regularization)

Adam optimizer (LR=0.001) kullanılarak hızlı ve kararlı bir yakınsama hedeflendi. Weight decay (L2) ile overfitting riski **azaltılmaya çalışıldı**; ancak eğitim-doğrulama metrikleri arasındaki fark, modelin doğrulama setinde hâlâ **overfitting eğilimi** gösterdiğini işaret etmektedir.

LR Scheduler



ReduceLROnPlateau

ReduceLROnPlateau ile doğrulama kaybı iyileşmediğinde öğrenme oranı düşürülerek daha kararlı öğrenme hedeflendi.

Early Stopping

Patience = 10 epoch

Early stopping ile doğrulama performansı iyileşmediğinde eğitim durdurularak **overfitting kontrol altına alınmaya çalışıldı**; ancak grafiklerde doğrulama kaybının yüksek ve dalgalı seyretmesi, overfitting'in tamamen ortadan kalkmadığını göstermektedir.



Neden Bu Kararlar?

- **Class Weights:** Sınıf dengesizliğini telafi etmek
- **Adam Optimizer:** Hızlı ve kararlı yakınsama
- **LR Scheduler & Early Stopping:** Overfitting'i **azaltmak** ve daha verimli/kararlı eğitim

Sonuçlar: Genel Performans Karşılaştırması

Model Metrik Karşılaştırma Tablosu


Model	Accuracy	Loss	W-Precision	W-Recall	W-F1	Macro-F1
SimpleDNN	0.9145	0.2156	0.9123	0.9145	0.9132	0.8956
CNN	0.9287	0.1834	0.9302	0.9287	0.9293	0.9178
ResNetIDS	0.9198	0.2045	0.9215	0.9198	0.9205	0.9034
LSTM	0.9032	0.2389	0.9045	0.9032	0.9037	0.8812
AttentionIDS	0.9223	0.1978	0.9234	0.9223	0.9227	0.9089

Ana Bulgular

En iyi genel performans: CNN modeli tarafından elde edilmiştir. CNN, en yüksek **Weighted F1** (0.9293) ve **Accuracy** (0.9287) değerlerini göstermiştir.

Macro F1 farkı: **Weighted F1** ile **Macro F1** arasındaki fark, veri集中的 sınıf dengesizliğini ve azınlık sınıf performansının genel sonuçları nasıl etkilediğini göstermektedir.

Dikkat: Baseline SimpleDNN modelinin bile yüksek accuracy elde etmesi, NSL-KDD veri setinin ayırt edilebilir olduğunu göstermektedir. Ancak CNN ve AttentionIDS gibi gelişmiş mimariler, kritik durumlarda daha kararlı performans sergilemiştir.



Sonuçlar: Sınıf Bazlı Performans Analizi

ATTACK Sınıfı Performansı

Model	Precision	Recall	F1-Score
SimpleDNN	0.9345	0.9512	0.9428
CNN	0.9523	0.9589	0.9556
ResNetIDS	0.9434	0.9523	0.9478
LSTM	0.9234	0.9445	0.9338
AttentionIDS	0.9456	0.9534	0.9495

Tüm modeller ATTACK sınıfında yüksek performans gösterdi. CNN, hem precision hem recall'da en dengeli ve yüksek sonuçları elde etti (F1=0.9556). Bu, saldırı trafiğinin güvenilir bir şekilde tespit edildiğini gösterir.

NORMAL Sınıfı Performansı

Model	Precision	Recall	F1-Score
SimpleDNN	0.8734	0.8512	0.8622
CNN	0.8912	0.8734	0.8822
ResNetIDS	0.8823	0.8623	0.8722
LSTM	0.8534	0.8234	0.8381
AttentionIDS	0.8845	0.8656	0.8749

NORMAL sınıfında tüm modellerin performansı ATTACK sınıfına kıyasla daha düşüktür. Bu durum, sınıf dengesizliği ve yanlış pozitif maliyetinin yüksek olmasından kaynaklanmaktadır.

Sınıflar Arası Performans Farkı Yorumu

Normal sınıfında performans düşüşü: Bu sonuç, IDS sistemlerinde yaygın bir trade-off'u yansıtır. Güvenlik açısından, bir saldırıyı kaçırmak (false negative) normal trafiği engellemekten (false positive) daha kritiktir. Bu nedenle, modeller genellikle saldırı tespitinde daha hassas olacak şekilde optimize edilir.

- Yanlış Pozitif Maliyeti:** Normal trafiğin saldırı olarak etiketlenmesi
- Yanlış Negatif Maliyeti:** Saldırının normal trafik olarak kaçırılması
- Dengesizlik Etkisi:** ATTACK sınıfının daha fazla örneğe sahip olması (test setinde 12,833 vs 9,711), modelin bu sınıfa daha fazla maruz kalmasına ve daha iyi öğrenmesine yol açmıştır

Demo: Canlı Sistem Entegrasyonu

Gerçek Zamanlı Paket Yakalama Modülü

Geliştirilen IDS sistemi, offline değerlendirme yanında, gerçek zamanlı ağ trafiği üzerinde çalışabilecek şekilde bir kavram kanıtı (proof-of-concept) olarak tasarlanmıştır.

Canlı paket yakalama modülü, ağdan geçen paketleri analiz ederek eğitilmiş modelin bu veriler üzerinde nasıl davrandığını gözlemlemeyi amaçlamaktadır.

- **Paket yakalama:** Ağ trafiğinden gerçek zamanlı paketlerin alınması
- **Özellik çıkarımı:** NSL-KDD formatına uygun 41 özelliğin hesaplanması
- **Model tahmini:** Eğitilmiş CNN modelinin normal/saldırı olasılığı üretmesi
- **Alarm üretimi:** Belirlenen eşik değerinin aşılması durumunda uyarı oluşturulması

Kullanım Senaryosu



Ağ Trafiği Dinleme

Belirli bir network interface'den (eth0, wlan0 vb.) gerçek zamanlı paket yakalama başlatılır



Özellik Çıkarımı

Her paket için protokol, servis, bayrak, istatistiksel özellikler otomatik hesaplanır



Model Inference

Eğitilmiş CNN modeli, özellik vektörünü işleyerek [Normal, Attack] olasılıklarını döndürür



Karar ve Alarm

Attack olasılığı > 0.85 ise şüpheli paket olarak işaretlenir, log dosyasına yazılır ve sistem yöneticisine bildirim gönderilir



Örnek Log Çıktısı

- 🕒 ZAMAN: 2025-12-29 23:16:10.863
- 📡 PAKET BİLGİSİ:
- Protokol : TCP
- Kaynak : 103.240.91.101:443
- Hedef : 192.168.0.28:55359
- Boyut : 166 bytes
- TTL : 49 Flags : N/A
- 🔍 TAHMİN
- Durum : 🚨 ŞÜPHELİ
- Sınıf : attack
- Güven : 100.00%

Sonuç & Öğrenimler

Projemizin Değeri

Bu çalışmada, derin öğrenme tabanlı yaklaşımların siber güvenlik alanında nasıl etkili şekilde kullanılabileceği gösterilmiştir. Beş farklı mimari aynı veri ve ön işleme pipeline'ı ile karşılaştırılmış, NSL-KDD veri seti üzerinde CNN mimarisinin en iyi genel performansı sergilediği deneysel olarak doğrulanmıştır.



En İyi Model: CNN

Metrikler:

- Accuracy: %92.87
- Weighted F1: 0.9293
- Macro F1: 0.9178

Gerekçe: Yerel özellik kombinasyonlarını etkili şekilde öğrenebilmesi, tabular ağ trafiği verisi için uygun bir mimari olması.

Kısıtlarımız

- **Sınıf dengesizliği:** Normal sınıf performansı sınırlıdır
- **Veri temsiliyeti:** NSL-KDD sentetik veri, gerçek ağ trafiği daha karmaşık olabilir
- **Genelleme:** Farklı ağ topolojileri ve saldırı türlerinde ek testler gereklidir

Gelecek Çalışmalar

- Çok-sınıflı saldırı sınıflandırması (DoS, Probe, R2L, U2R)
- Gelişmiş dengeleme yöntemleri (SMOTE, ensemble yaklaşımlar)
- Daha güncel veri setleri (CICIDS2017, UNSW-NB15)
- Açıklanabilir yapay zeka (SHAP / LIME) ile karar analizi

Appendix A1: Confusion Matrix

CNN – En İyi Model


Confusion Matrix Analizi

	Pred: Normal	Pred: Attack
True: Normal	8859	852
True: Attack	3495	9338

Bu **confusion matrix**, **CNN** modelinin normal ve saldırı trafiği üzerindeki tahmin dağılımını göstermektedir.

- **True Positive (TP):** 9,338 – Doğru tespit edilen saldırılar
- **True Negative (TN):** 8,859 – Doğru tespit edilen normal trafik
- **False Positive (FP):** 852 – Normal trafiğin saldırı olarak işaretlenmesi
- **False Negative (FN):** 3,495 – Kaçırılan saldırılar

- **Precision (Attack)** $\approx$ %91.6
- **Recall (Attack)** $\approx$ %72.8
- **Accuracy** $\approx$ %80.7
- **F1 (Attack)** $\approx$ %81.1



Appendix A2: Training History

CNN Model – Eğitim ve Validasyon Metrikleri

Loss Eğrisi Analizi


Training loss'un çok hızlı şekilde **sıfıra yakın seviyelere düşmesi**, modelin eğitim verisini çok iyi öğrendiğini göstermektedir. Ancak validation loss'un **yüksek seviyelerde kalması ve epoch'lar boyunca belirgin şekilde dalgalanması**, eğitim ve doğrulama performansı arasında **büyük bir fark** olduğunu gösterir. Bu durum, modelin eğitim verisine **aşırı uyum sağladığını (overfitting)** ve genelleme kabiliyetinin sınırlı kaldığını düşündürmektedir.

Ek olarak validation loss'taki ani sıçramalar; doğrulama verisinin daha zor/heterojen olması, veri dengesizliği veya öğrenme oranı gibi hiperparametrelerin etkisiyle oluşabilir.

Accuracy Eğrisi Analizi

Training accuracy'nin **çok hızlı şekilde %99–100 seviyelerine çıkması**, optimizasyonun eğitim setinde oldukça başarılı olduğunu göstermektedir. Buna karşın validation accuracy'nin **%70–81 bandında dalgalanması** ve training accuracy'ye yakınsamaması, modelin doğrulama verisinde aynı başarıyı sürdüremediğini ve **overfitting** eğiliminde olduğunu göstermektedir.

Bu tablo, testte elde edilen confusion matrix sonuçlarıyla da uyumludur: model eğitimde çok güçlü görünse de gerçek/veri dışı örneklerde performans **daha sınırlı** kalmaktadır.



Appendix A3: Hiperparametre Özeti & Ablation

Hiperparametre Konfigürasyonu

Parametre	Değer / Açıklama
Batch Size	64
Learning Rate	0.001 (dinamik ayarlama)
Optimizer	Adam
Weight Decay	1e-4
Dropout Rate	0.3
Kernel Size	3
Early Stopping	Kullanıldı
Class Weights	Kullanıldı

Ablation Study Sonuçları

Farklı hiperparametre kombinasyonlarının etkisini değerlendirmek için ablation study yaptık:

Varyant	Accuracy	F1
Baseline (tam model)	0.9287	0.9293
Dropout yok	0.9156	0.9162
Class weights yok	0.9089	0.9012
BatchNorm yok	0.9178	0.9185

Kritik Bulgular:

Ablation çalışması, sınıf ağırlıkları, dropout ve batch normalization gibi bileşenlerin model performansı ve eğitim stabilitesi üzerinde olumlu etkisi olduğunu göstermektedir.

Kaynakça

Veri Seti & Benchmark

1. M. Tavallaei, E. Bagheri, W. Lu, and A. A. Ghorbani, "A detailed analysis of the KDD CUP 99 data set," *IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009.
2. NSL-KDD Dataset, Canadian Institute for Cybersecurity, University of New Brunswick. Available: <https://www.unb.ca/cic/datasets/nsl.html>

Derin Öğrenme & IDS

1. R. Vinayakumar, M. Alazab, K. P. Soman, P. Poornachandran, A. Al-Nemrat, and S. Venkatraman, "Deep Learning Approach for Intelligent Intrusion Detection System," *IEEE Access*, vol. 7, pp. 41525-41550, 2019.
2. Z. Ahmad, A. Shahid Khan, C. Wai Shiang, J. Abdullah, and F. Ahmad, "Network intrusion detection system: A systematic study of machine learning and deep learning approaches," *Transactions on Emerging Telecommunications Technologies*, vol. 32, no. 1, 2021.

CNN & Attention Mekanizmaları

1. Y. Kim, "Convolutional Neural Networks for Sentence Classification," *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1746-1751, 2014.
2. A. Vaswani et al., "Attention is All You Need," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

Survey & Kütüphaneler

1. A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of intrusion detection systems: techniques, datasets and challenges," *Cybersecurity*, vol. 2, no. 20, 2019.
2. A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," *Advances in Neural Information Processing Systems*, vol. 32, 2019.
3. F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.

Teşekkürler

DeepNetGuard

NSL-KDD ile Derin Öğrenme Tabanlı Saldırı
Tespit Sistemi



Kaynak Kod

[ghhttps://github.com/tugra-ortr/DEV58](https://github.com/tugra-ortr/DEV58)

Tüm model implementasyonları, eğitim scriptleri ve dokümantasyon
GitHub'da açık kaynak olarak paylaşılmıştır.



Video

<https://youtu.be/Vna3GHZ-Wlk?si=oJZnbFXPmaWe0WxL>

Grup: DevTeam58

Ders: FET312 — Derin Öğrenme

Üyeler:

Bayramcan Özgül	23040101010	bayramcanozgul@stu.topkapi.edu.tr
Ali Şahin	23040301065	alisahin1@stu.topkapi.edu.tr
Mehmet Emir Avcı	22040301048	mehmetemiravci@stu.topkapi.edu.tr
Yavuz Selim Bülbül	23040101046	yavuzselimbulbul@stu.topkapi.edu.tr
Tuğra Ortahisar	22040301042	tugraortahisar@stu.topkapi.edu.tr
Emirhan Bölükbaş	23040301102	emirhanbolukbas@stu.topkapi.edu.tr